

Çelik Yüzey Kusuru Sınıflandırması

23040301067 – Mustafa ÖZBEZEK

23040301045 – Mehmet Kerem HAKAN

Ekip Adı: DevENG

İstanbul Topkapı Üniversitesi – Mühendislik Fakültesi Yazılım
Mühendisliği Bölümü

GitHub:

github.com/keremh9/DevENG_DeepLearning_Project_FET312

YouTube Link: <https://youtu.be/lCsRilibHCc?si=b1LgLIZ65YjTtMXz>

PROBLEM TANIMI VE MOTİVASYON

Sektörel Sorun ve İş Sorusu: Sıcak haddelenmiş çelik üretiminde oluşan yüzey kusurlarını, kaliteti doğrudan düşürmekte ve maliyetli geri dönüşlere yol açmaktadır. Peki bu kusurlar insan faktörü olmadan , yapay zeka ile %100 güvenilir şekilde sınıflandırılabilir mi ?

Neden Derin Öğrenme? İnsan Faktörü: Geleneksel gözle kontrol yöntemleri yavaşır, yorucudur ve kişisel yorumlara dayalı hata payı yüksektir.

Otomasyon: 7/24 kesintisiz denetim ve fabrikadaki yüksek üretim hızına uyum sağlayan anlık tespit kapasitesi. **Maliyet:** Hatalı ürünlerin erkenden elenmesiyle sağlanan operasyonel verimlilik.

Projenin Hedefi:

NEU Surface Defect veri setini kullanarak; Baseline CNN ile gelişmiş modellerin (ResNet18, EfficientNet) kıyaslanması ve en optimum çözümün sunulması..

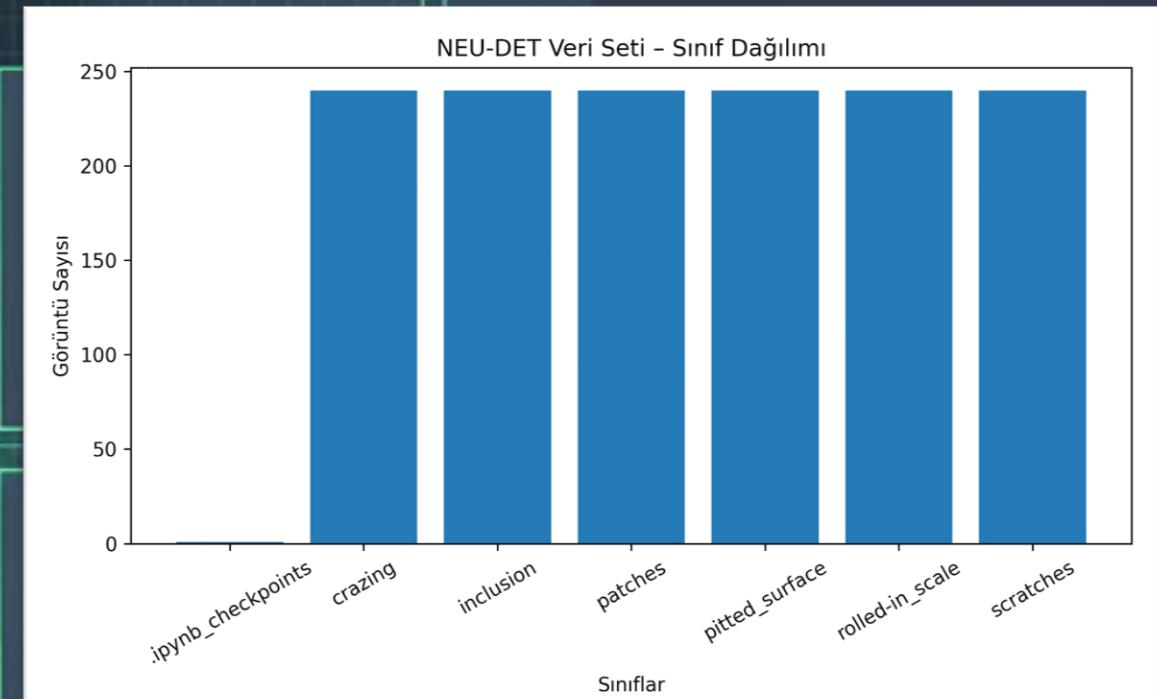
VERİ KÜMESİ VE KUSUR SINIFLARI

NEU Surface Defect Veri Seti Özellikleri:

Toplam Görüntü: 1800 adet yüksek çözünürlüklü metal yüzey fotoğrafı.

Sınıf Dağılımı: 6 farklı kusur türü, her sınıf için 300 dengeli örnek.

Format: 224x224 piksel, gri tonlu (grayscale) görüntüler.



Sınıflandırılan 6 Temel Kusur Türü

Crazing (İnce Çatlaklar): Yüzeydeki ağısı mikro çatlaklar.

Inclusion (Yabancı Madde): Metal içine karışmış istenmeyen partiküller.

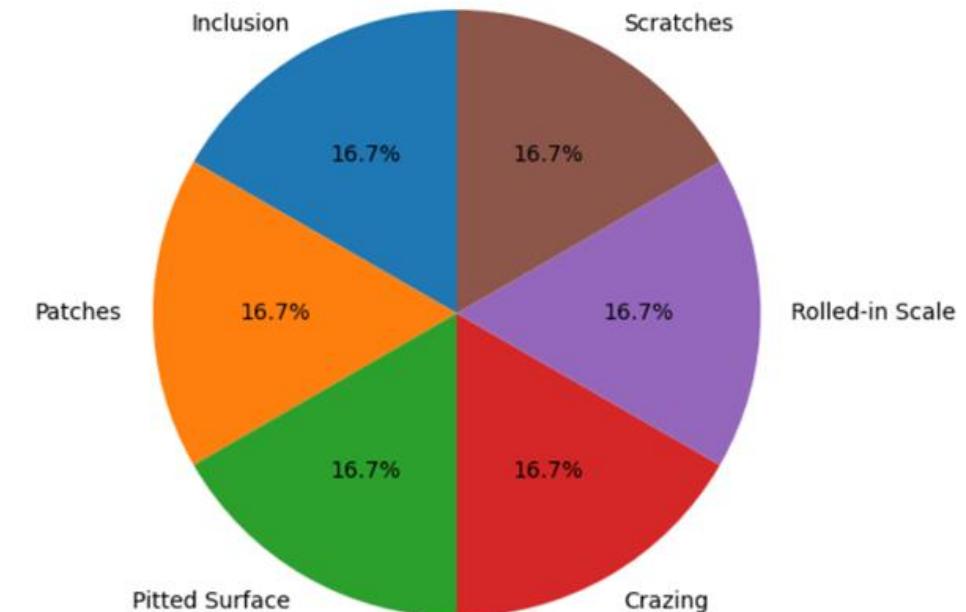
Patches (Yamalar): Yüzeydeki düzensiz tabaka değişimleri

Pitted Surface (Çukurlu Yüzey): Korozyon kaynaklı küçük delikler.

Rolled-in Scale (Haddelenmiş Pül): Üretim sırasında yapışan oksit tabakası.

Scratches (Çizikler): Mekanik kaynaklı doğrusal izler.

Class Distribution of NEU Surface Defect Dataset



MODEL MİMARİLERİ VE EĞİTİM STRATEJİSİ

Kullanılan Mimari Yapılar:

- Vize aşamasında baseline CNN modelleri kullanılmıştır, final aşamasında ise gelişmiş derin öğrenme mimarileri eğitilmiş ve kullanılmıştır kullanılan mimariler ise aşağıdadır.

Kullanılan Gelişmiş Modeller:

ResNet18 (Frozen) – Kerem

ResNet18 (Fine-tune) – Kerem

EfficientNet-B0 (Frozen) – Mustafa

MobileNetV3-Small (Frozen) – Mustafa

Eğitim Parametreleri (Hiperparametreler):

Optimizer: Adam Optimizer (Dinamik öğrenme oranı yönetimi).

Loss Fonksiyonu: CrossEntropyLoss (Çok sınıflı sınıflandırma optimizasyonu).

Öğrenme Oranı (LR): 0.001 (Baseline) / 0.0005 (Gelişmiş katmanlar için).

Batch Size & Epoch: 32 Batch boyutu ve 10-15 Epoch eğitim süresi.

EĞİTİM PERFORMANSI VE BAŞARI METRİKLERİ

Modeller Arası Başarı Kıyaslaması: Başlangıç seviyesindeki SimpleCNN modellerimiz ile %83 doğruluk (Accuracy) seviyesine ulaştık.

Gelişmiş mimarilere geçtiğimizde ise EfficientNet-B0 ile %97.78, ResNet18 Fine-tune modelimizle ise %100 tam doğruluk elde ettik.

Sınıf Bazlı Model Başarımı: Crazing, Patches ve Rolled-in Scale gibi kusurlar modellerimiz tarafından kusursuz bir şekilde sınıflandırılmıştır. Özellikle sınıflandırılması en zor olan 'Inclusion' ve 'Pitted Surface' sınıflarında, uyguladığımız Fine-tuning stratejisi sayesinde %100 F1-skoruna ulaştık.

Eğitim Karakteristiği ve Stabilite: Eğitim ve doğrulama kayıp eğrilerimizin birbiriyle uyumlu ilerlemesi, modellerimizin ezberlemediğini yanı yüksek genelleme yeteneğine sahip olduğunu göstermektedir.

Mühendislik Çıkarımı: Bu sonuçlar, derin öğrenme modellerinin çelik sanayisindeki kalite kontrol süreçlerinde insan hatasını sıfıra indirmeye potansiyelini teknik olarak kanıtlamaktadır.

KARŞILAŞILAN ZORLUKLAR VE ÇÖZÜM YÖNTEMLERİ

Veri Ön İşleme Zorlukları: Gri tonlu görüntülerin (Grayscale) modern mimarilere (ResNet, EfficientNet) uyumlu hale getirilmesi için 3 kanallı "Pseudo-RGB" formatına dönüştürülmüş sağlanmıştır.

Aşırı Öğrenme (Overfitting) Engellemesi: Modellerin eğitim verisini ezberlemesini önlemek amacıyla Mustafa tarafından "Rotation, Random Crop ve Flip" gibi kapsamlı veri artırma (augmentation) teknikleri uygulanmıştır.

Hesaplama Maliyeti: Derin modellerin (ResNet18) eğitim hızını artırmak ve donanım kaynaklarını verimli kullanmak adına Batch Size 32 olarak optimize edilmiştir.

GELECEK VİZYONU VE ENDÜSTRİ 4.0 ENTEGRASYONU

Real-Time (Anlık) Karar Destek Sistemi: Geliştirdiğimiz algoritmanın yüksek işlem hızı sayesinde, üretim bandı üzerine yerleştirilen kameralarla saniyeler içinde hatasız denetim yapılması hedeflenmektedir.

Tam Otonom Kalite Kontrol: Hata tespit edildiği anda üretim bandını durdurulan veya kusurlu parçayı otomatik olarak ayıran bir PLC mekanizması ile entegre edilerek, insan müdahalesi gerektirmeyen "Sıfır Hata" fabrikaları vizyon edilmektedir.

GENEL DEĞERLENDİRME VE PROJE KAPANIŞI

Akademik ve Teknik Kazanımlar: Proje süresince hem özgün CNN mimarileri tasarlanmış hem de **ResNet18** ve **EfficientNet-B0** gibi modern mimarilerin çelik yüzey kusurları üzerindeki başarımı karşılaştırmalı olarak kanıtlanmıştır.

Mühendislik Yaklaşımı: Hiperparametre optimizasyonu, stratified veri bölme stratejileri ve kapsamlı performans analiz metrikleri kullanılarak endüstriyel bir problemin çözüm süreçleri uçtan uca deneyimlenmiştir.

Açık Kaynak ve Erişim: Bilimsel şeffaflık adına projemizin tüm kaynak kodları, veri setleri ve analiz raporları **GitHub** depomuzda kamuya açık olarak paylaşılmıştır.

Teşekkür: Sabrınız ve değerli vaktiniz için teşekkür ederiz.